科展混合文本檢測之性能與能源效率研究

摘要

生成式 AI 的普及使人機協作文本日益增加，傳統方法難以有效辨識混合文本，且大型模型亦面臨高運算成本與能耗問題。本研究針對此情境，系統性比較模型架構、微調策略與模型規模對性能、預測可靠性與能源效率之影響。

研究重點：探討混合文本（三分類）檢測任務、分析「模型架構×微調策略×模型規模」之影響

實驗設計：雙環境：RTX 4090（訓練）＋ RTX 3070（推論）、資料集：PAN’25

模型效能：ModernBERT-base LoRA-All → F1 = 98.41% 與全參數微調無顯著差異（McNemar’s test）、預測可靠性ECE=0.012顯示較佳機率校準與較低過度自信

能源效率：功耗：381.3W → 129.6W（↓ 2.7倍） 顯著降低訓練成本

關鍵發現：架構與微調策略影響＞模型規模擴張Base模型已可達高效能，Large 沒有帶來顯著提升

透過現代化模型架構結合參數高效微調，可在高性能、良好校準與低能耗之間取得平衡，為混合文本檢測提供具實務價值之方向。

研究動機

隨著大型語言模型（Large Language Model, LLM）的快速發展，生成式 AI 已經能夠產出語句流暢、邏輯清晰的文本，使內容生成的成本大幅降低。這項技術在提升生產效率的同時，也對學術誠信與內容可信度帶來新的挑戰。目前多數 AI 文本檢測系統仍以二元分類為主，僅區分「純人類撰寫」與「純機器生成」文本。然而，在實際應用情境中，人機協作已相當普遍，混合文本逐漸成為常態。這類文本同時包含人類與 AI 的語言特徵，使其在結構與語氣上更為複雜，也提高了辨識難度，導致傳統檢測方法的準確率下降。

研究目的

（一）驗證參數高效微調在檢測型任務可行性
（二）評估不同模型架構的效能與能耗效益
（三）允許大型模型在消費級硬體上運行

研究設備及器材

硬體設備訓練環境使用 RunPod 雲端運算平台（NVIDIA RTX 4090，24GB VRAM）
本地推論環境使用（NVIDIA RTX 3070，8GB VRAM）

研究流程

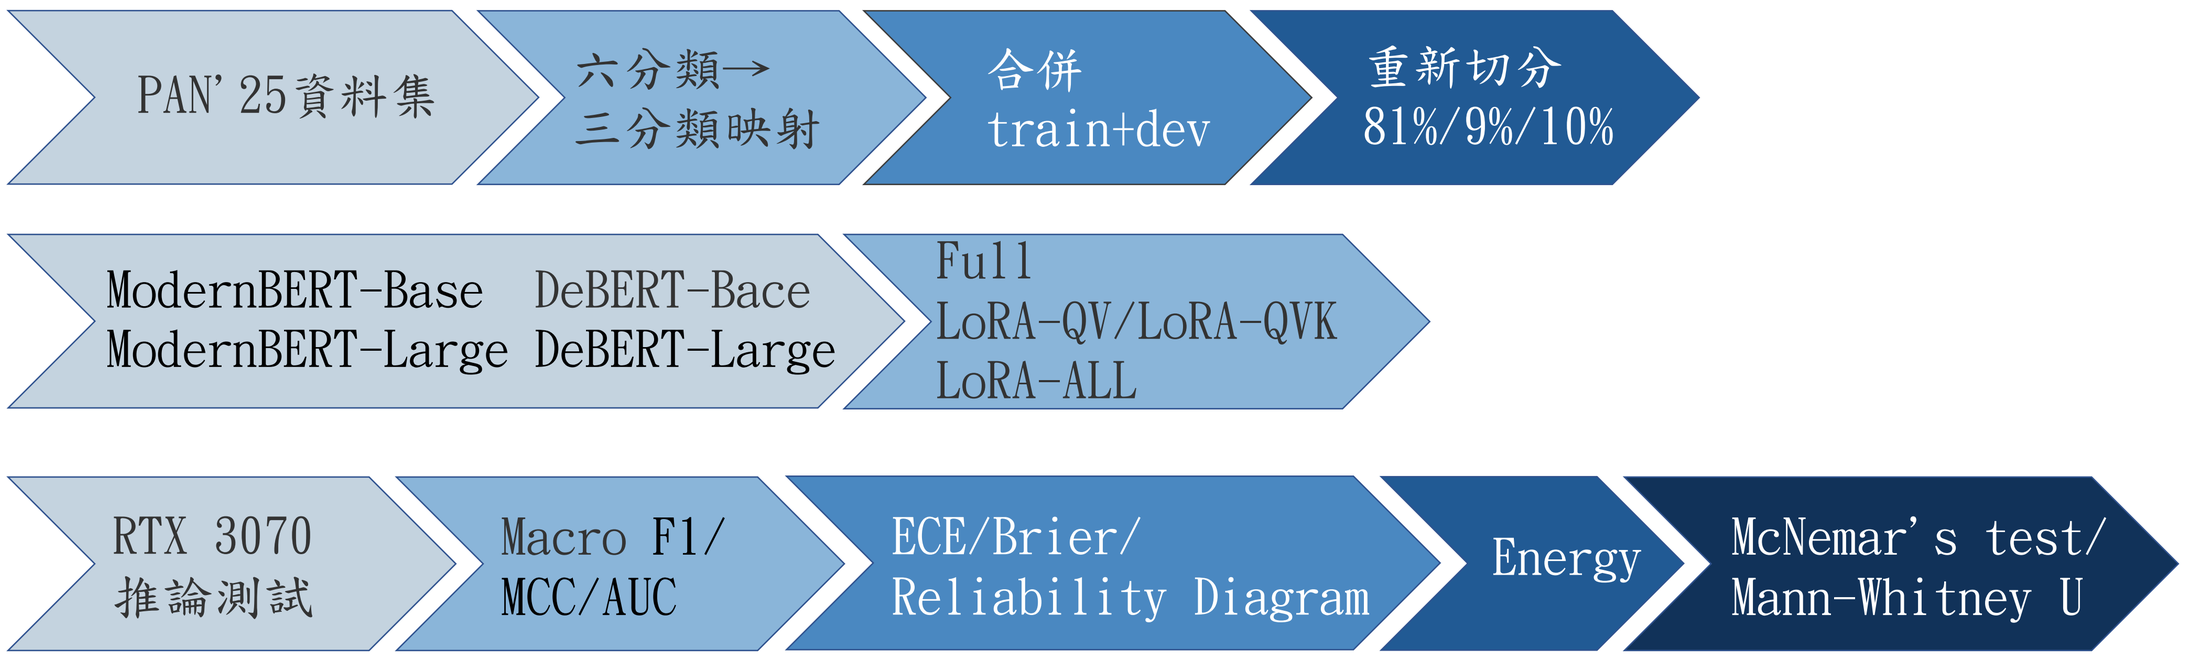

研究方法

本研究使用了公開資料集
「PAN’25 Generative AI Detection: Human-AI Collaborative Text Classification」

本研究分類	分類定義	原始標籤
Human	完全由人類撰寫	Fully human-written
AI	完全由人工智慧生成	Machine-written, then machine-humanized
Mixed	人類與人工智慧共同參與撰寫或修改	Human-written, then machine-polished
		Human-initiated, then machine-continued
		Machine-written, then human-edited
		Deeply-mixed text

實驗設計

實驗	模型	學習率	訓練方法	輪數
一：模型架構比較	DeBERTa-v3-Base	2e-5	Full-Finetuning	3
	ModernBERT-Base	8e-6		
二：微調策略探討	DeBERTa-v3-Base	2e-5	LoRA-QV	
			LoRA-All	
三：Large模型LoRA效率比較	DeBERTa-v3-Large	5e-5	Lora-All	
	ModernBERT-Large	1e-4		
四：模型規模比較	DeBERTa-v3-Base	2e-5	Full-Finetuning	
	DeBERTa-v3-Large	5e-5	Lora-All	
五：ModernBERT LoRA Target比較	ModernBERT-Base	2e-4	LoRA-QKV	
	ModernBERT-Base		LoRA-All	

2 實驗結果

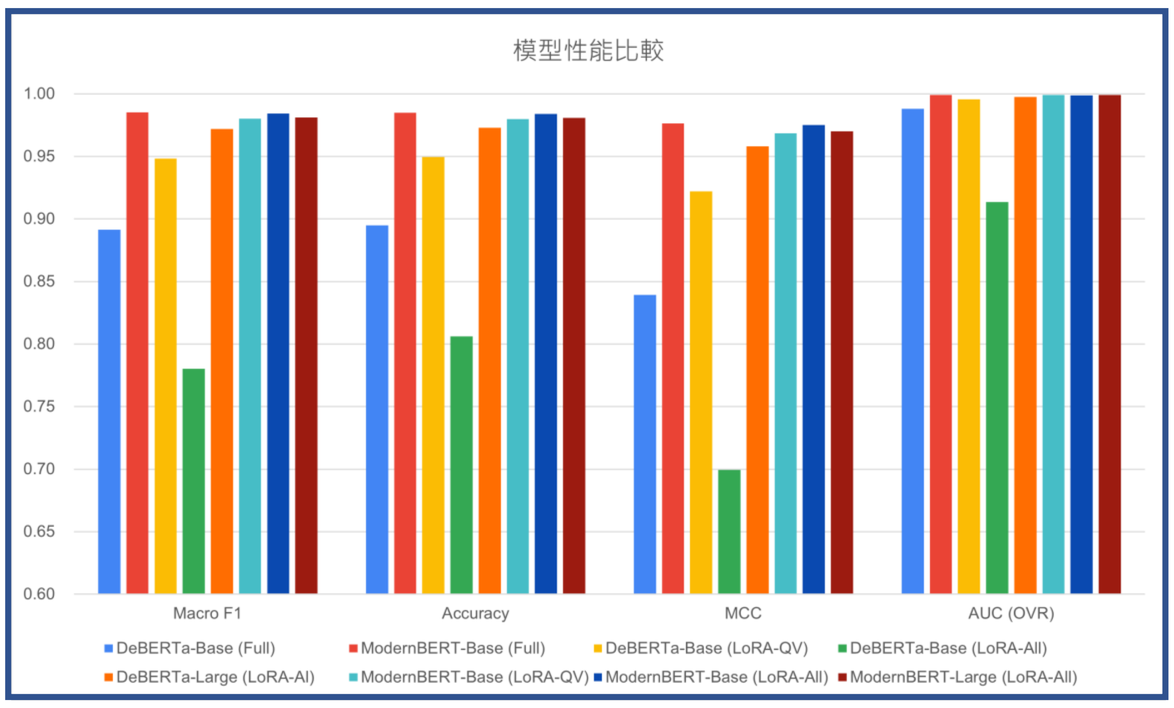

ModernBERT在 Macro F1、Accuracy 等各項指標上較優於 DeBERTa-v3。

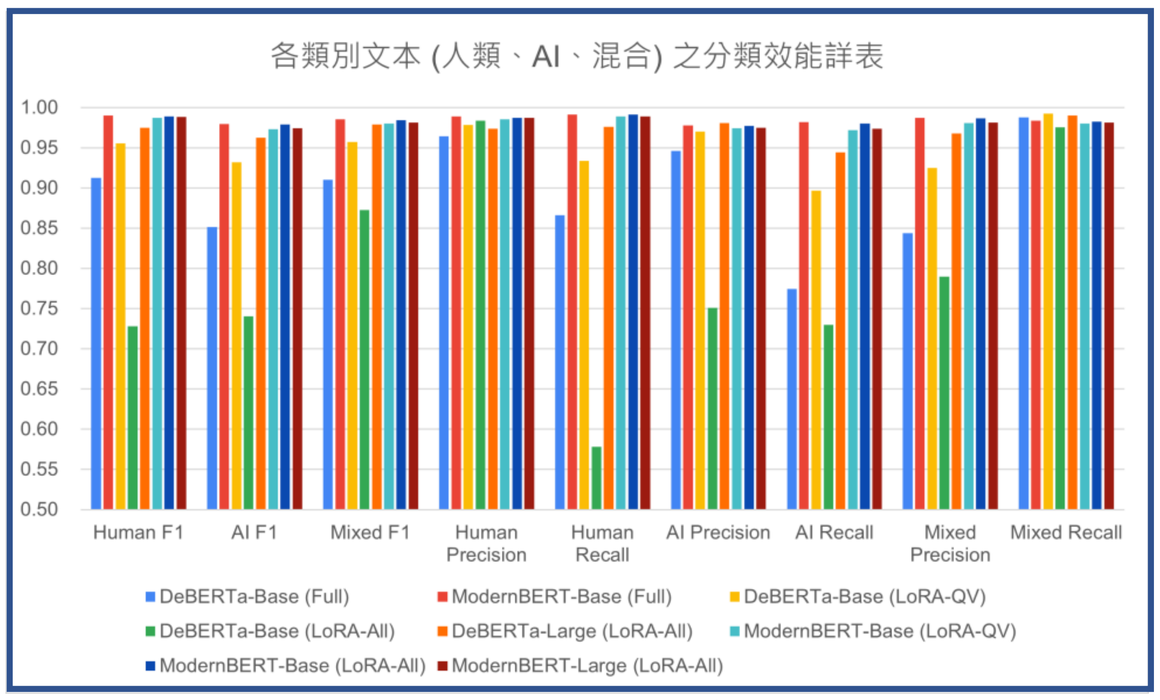

指出檢測瓶頸在於 AI 與 Mixed 的邊界，ModernBERT 能讓兩者的辨識能力更為均衡 。

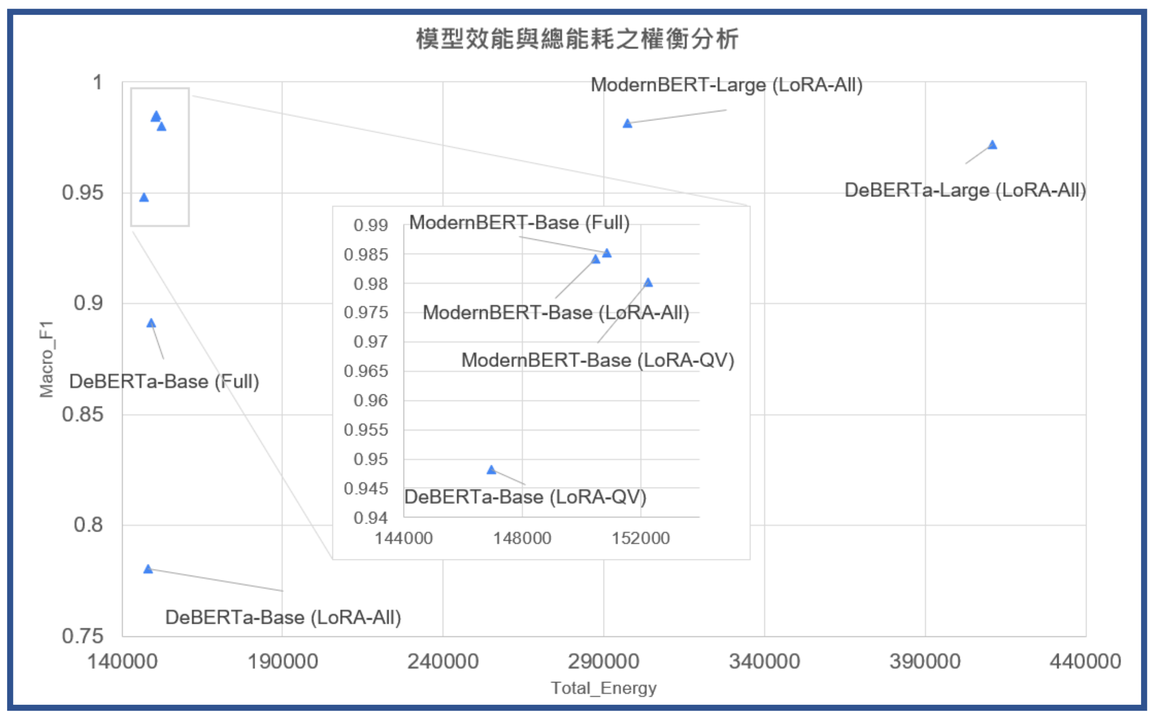

揭示 ModernBERT-Base 位於「高性能、中等能耗」的較佳位置，而大型模型則出現能耗翻倍但性能停滯的現象。

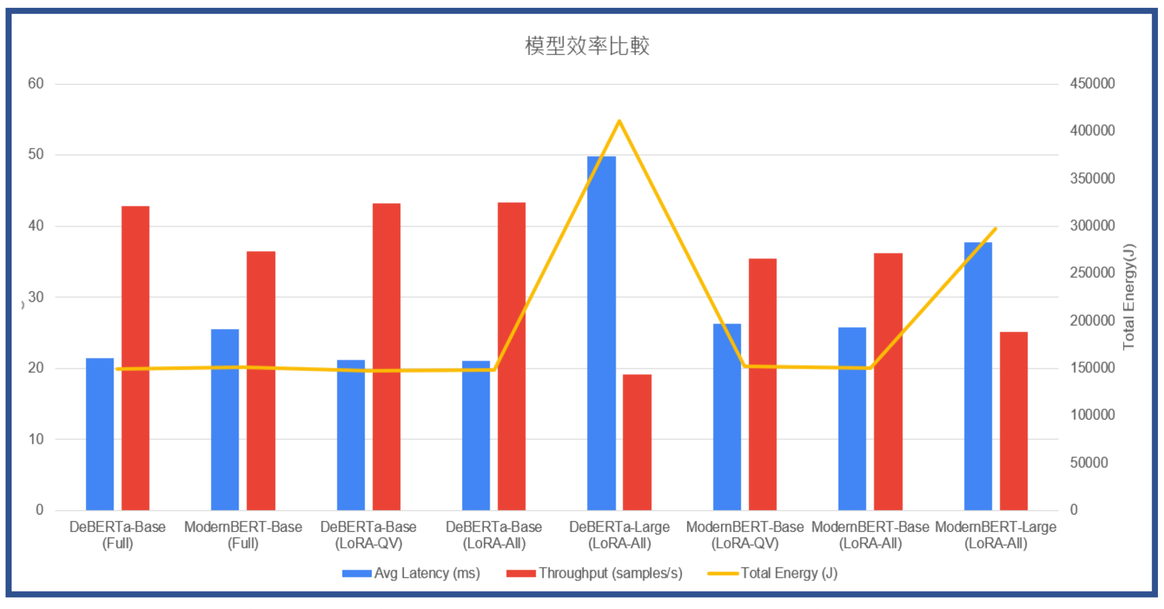

LoRA 訓練策略能節省大量訓練功耗的同時也沒有明顯降低效率。

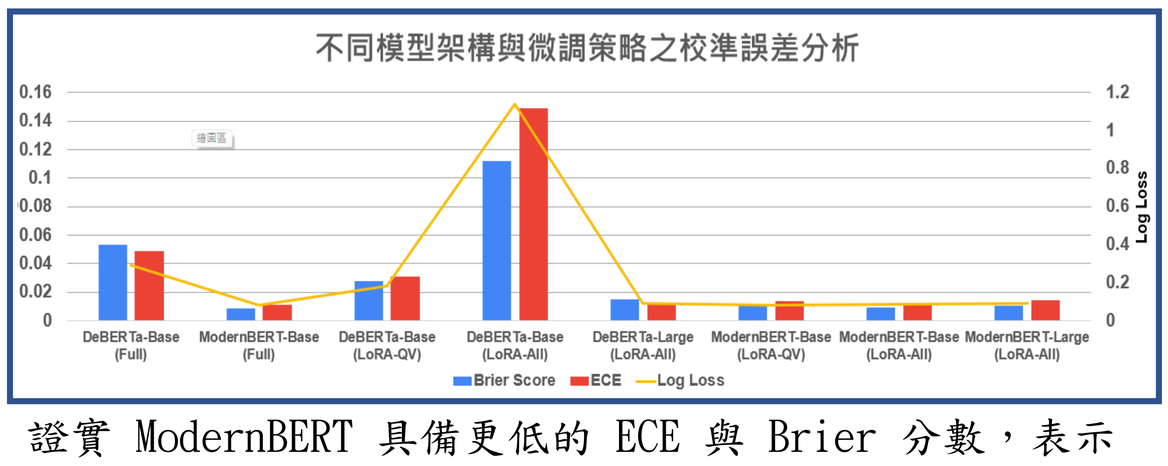

證實 ModernBERT 具備更低的 ECE 與 Brier 分數，表示預測機率更符合真實正確率，不易「過度自信」 。

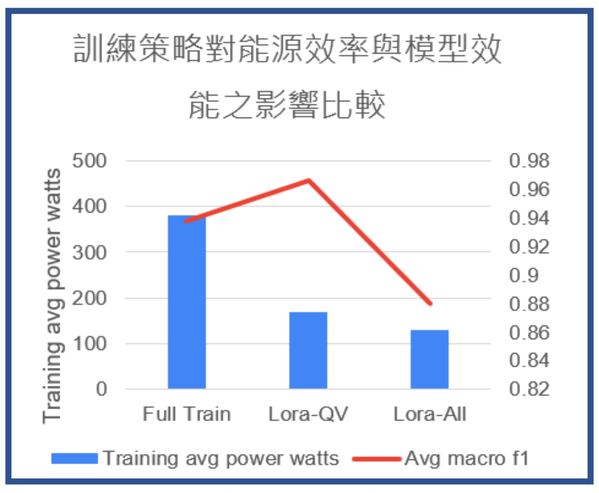

LoRA 訓練策略能節省大量訓練功耗，較接近「低碳高效」的綠色運算目標。

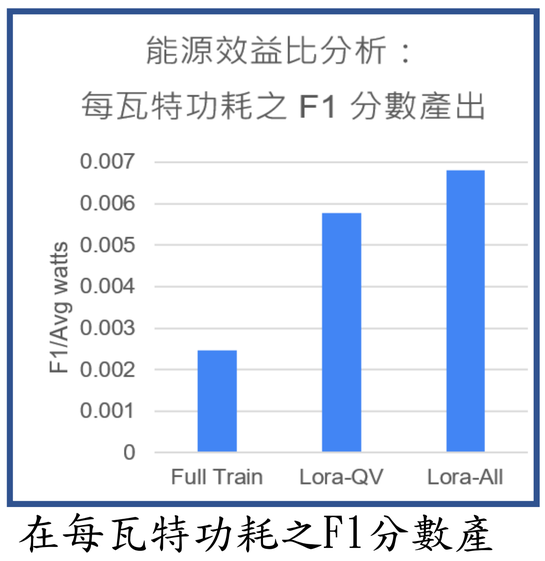

在每瓦特功耗之F1分數產出的能源效益比中，LoRA-All的表現最為突出。

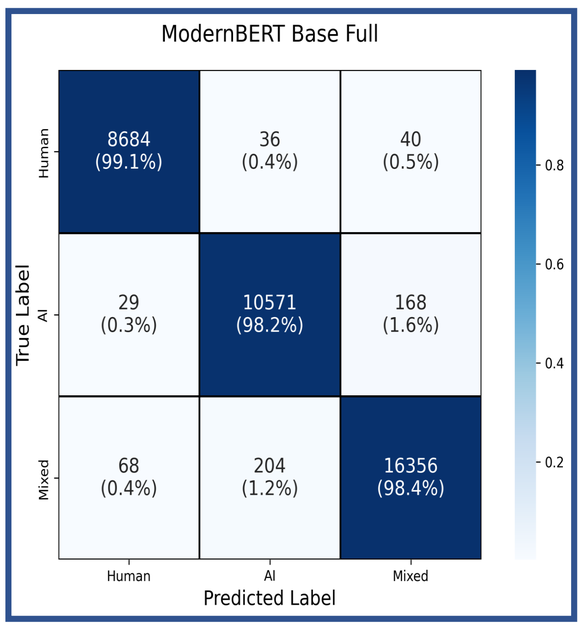

採用全參數微調的現代化架構展現了較強的特徵萃取能力，顯示其在處理高度相似的生成文本與潤飾文本時具備更銳利的決策邊界。

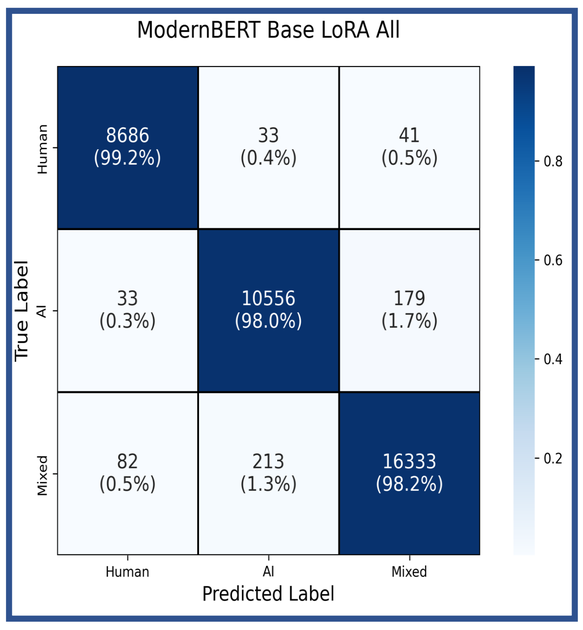

矩陣分佈與 Full 配置相似，從預測行為的層面顯示 LoRA-All能保留較多預訓練模型的分類能力，且未發生明顯性能退化。

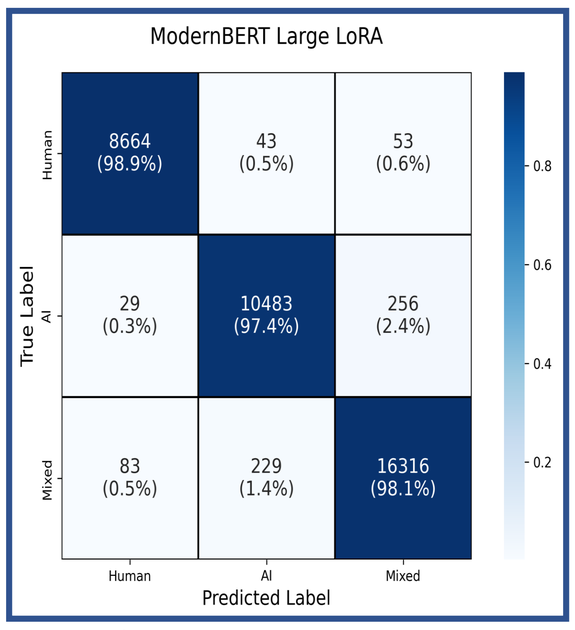

儘管參數規模擴大，但在 AI 類別的表現卻出現輕微退化。顯示大型模型面對此特定任務時，若僅依賴 LoRA可能存在優化難度增加的瓶頸。

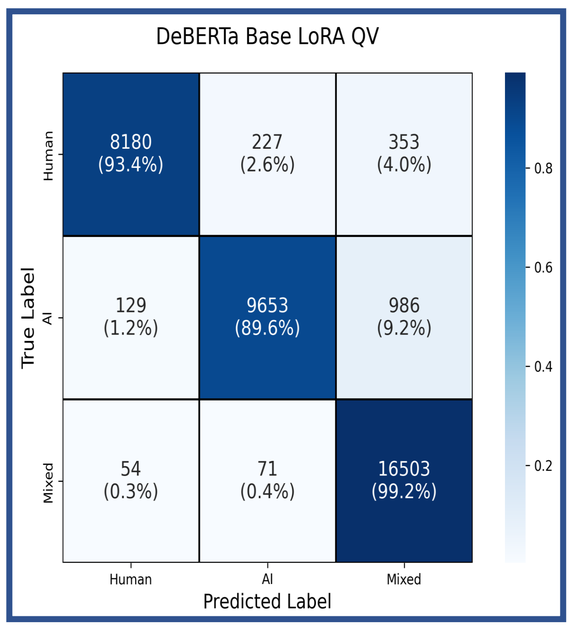

基準對照組，該模型在 AI 類別上的預測表現最為疲弱。這顯示舊有架構在捕捉人類與機器的複雜邊界時，容易產生特徵混淆。

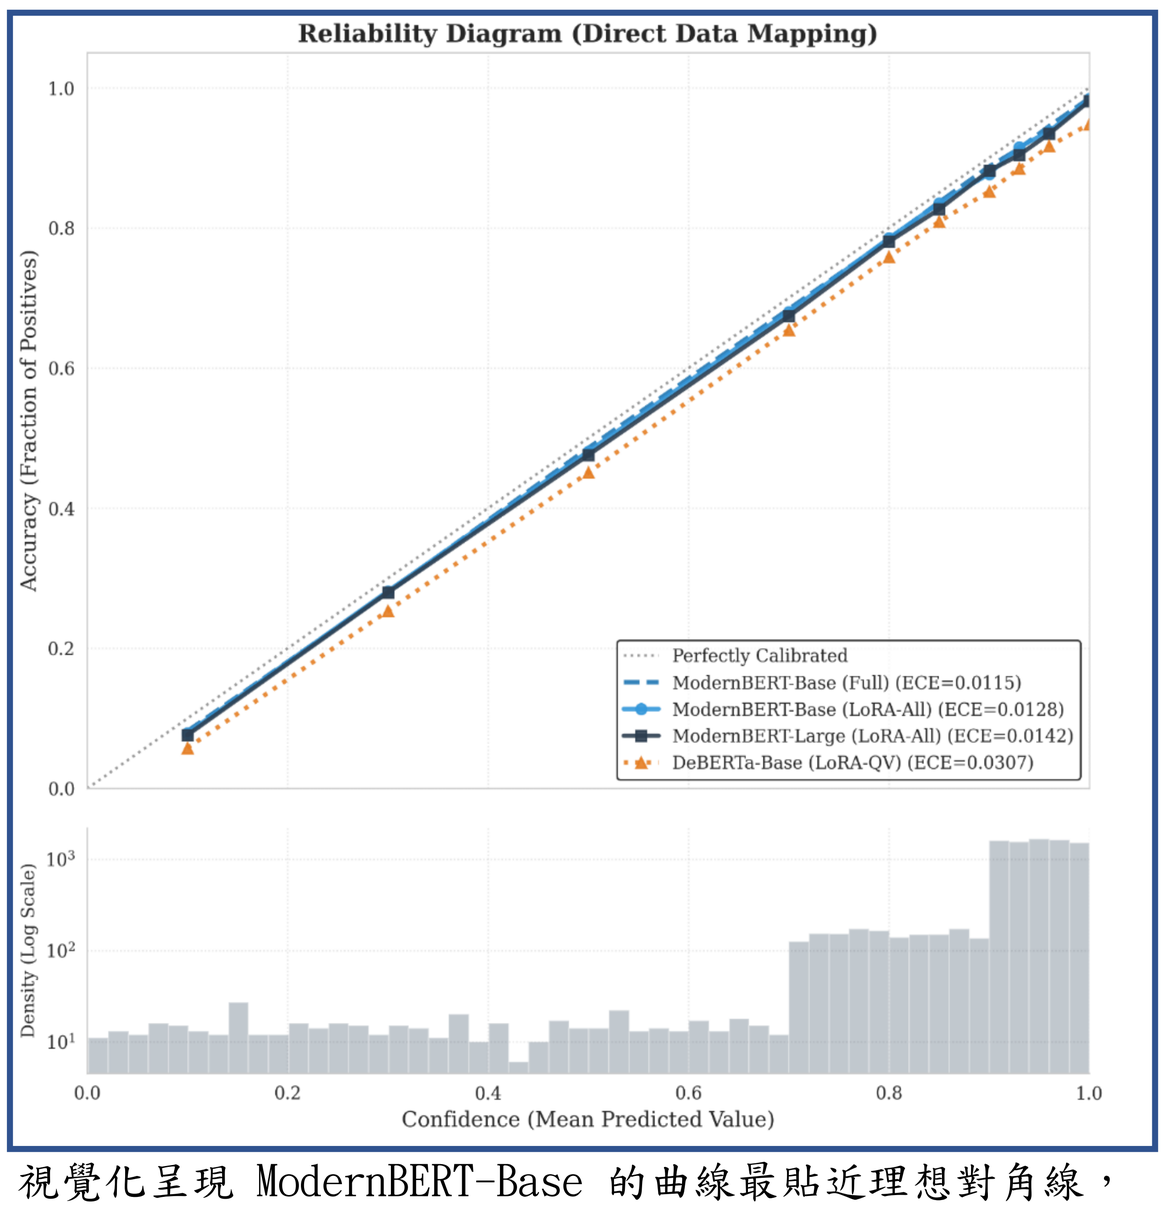

視覺化呈現 ModernBERT-Base 的曲線最貼近理想對角線，是目前較可靠的預測模型 。

核心模型整體性能與推論能效指標表						
模型配置	總體準確率	宏觀 F1	校準誤差	平均延遲	平均功耗	總能耗
ModernBERT-Base (Full)	98.49%	0.9851	0.0115	25.53	163.41	150866.5
ModernBERT-Base (LoRA-All)	98.39%	0.9841	0.0127	25.71	161.86	150471.7
ModernBERT-Large (LoRA-All)	98.08%	0.9811	0.0142	37.68	218.2	297345.4
DeBERTa-v3-Base (LoRA-QV)	94.96%	0.9482	0.0307	21.1	192.56	146974.7

表中結果顯示，ModernBERT 架構在整體表現上具有相對優勢。

各模型高信心錯誤樣本分析與統計檢定表(1)					
Model	Mean Conf (Error)	Median Conf (Error)	Error Conf > 0.9	Mixed Share (in >0.9 errors)	MWU p-value
ModernBERT-Base (LoRA-All)	0.9154	0.9871	73.84%	51.52%	-
ModernBERT-Large (LoRA-All)	0.8851	0.9728	64.21%	46.52%	0.0021957

規模擴張與架構選擇之性能與能耗差異分析表		
Comparison	ModernBERT-Base (LoRA-All) → ModernBERT-Large (LoRA-All)	DeBERTa—v3-Base (LoRA-All) → ModernBERT-Base (LoRA-All)
ΔMacro F1	-0.002966334	+0.20382875
ΔAccuracy	-0.003097688	0.20382875
ΔECE	0.001447629	0.177951101
ΔLatency (ms)	11.97792817	4.647916503
ΔPower (W)	56.3406915	-32.8289931
ΔEnergy (J)	146873.7531	2198.617016
Energy Change	97.60%	1.48%
Gain per 100kJ	-0.002019	9.27

在本研究任務中，模型規模擴張未必帶來性能提升。當模型由 Base 擴展至 Large 時，Macro F1 反而略為下降，同時總能耗顯著增加。此外，採用現代化架構可帶來正向能效回報，而單純擴大模型規模則呈現負回報。此結果顯示，相較於規模擴張，架構優化在性能與能效之間可能更具優勢，並對低碳運算與綠色 AI 之研究提供一定程度的實證參考。

各模型高信心錯誤樣本分析與統計檢定表(2)			
模型	錯誤樣本數	平均信心	信心中位數
ModernBERT-Base (LoRA-All)	581	0.9154	0.9871
ModernBERT-Large (LoRA-All)	693	0.8851	0.9728
統計檢定 (Base vs. Large)			MWU $p = 2.20 \times 10^{-3}$ ($p < 0.01$)

此表針對模型的過度自信誤判進行剖析。ModernBERT-Large 的錯誤樣本數（693筆）高於 ModernBERT-Base（581筆）。Mann-Whitney U 檢定結果（p=0.0021）證實兩者在錯誤信心分佈上有顯著差異。這顯示參數規模較大的模型在此任務中，面對難以辨識的邊界樣本時，其錯誤型態與信心分佈出現了的改變，顯示 Base 模型可能是更為穩健且經濟的選擇。

各模型 McNemar 統計檢定結果（P-value）比較表			
模型 A	模型 B	P-value (p)	顯著差異
ModernBERT-Base (Full)	ModernBERT-Base (LoRA-All)	0.0763	FALSE
ModernBERT-Base (LoRA-QV)	ModernBERT-Large (LoRA-All)	0.1413	FALSE
ModernBERT-Base (Full)	ModernBERT-Large (LoRA-All)	$9.07 \times 10^{(-10)}$	TRUE
ModernBERT-Base (Full)	DeBERTa-v3-Base (LoRA-QV)	$4.65 \times 10^{(-196)}$	TRUE
ModernBERT-Base (LoRA-All)	ModernBERT-Large (LoRA-All)	$2.61 \times 10^{(-6)}$	TRUE
DeBERTa-v3-Base (LoRA-QV)	ModernBERT-Base (LoRA-All)	$7.55 \times 10^{(-185)}$	TRUE

ModernBERT-Base 在 Full 與 LoRA-All 兩種配置下的對比，其 p-value 為 0.0763。相反地，ModernBERT 與 DeBERTa-v3 的比較皆呈現 $p < 0.05$，顯示了新架構帶來的性能提升並非隨機誤差，而是具有顯著差異的實質進步。

2 結論

本研究探討混合文本檢測任務中，不同模型架構、微調策略與模型規模對分類性能、預測可靠性與能源效率之影響。整體結果顯示，模型架構與微調策略相較於單純規模擴張，對於性能與能效之平衡可能具有更關鍵之影響，惟相關結論仍有待於不同資料條件與任務設定下進一步驗證。

主要發現如下：

1. 模型架構比較： ModernBERT 在多數評估指標上整體優於 DeBERTa-v3，不僅分類準確率與 Macro F1 較高，在機率校準指標（ECE、Brier Score、Log Loss）上亦呈現較穩定之趨勢，顯示其預測信心表達可能具有較高一致性。
2. 微調策略分析： LoRA-All 在本研究設定下能於維持接近全參數微調性能的同時，有效降低訓練資源需求與能源消耗；經統計檢定後，LoRA-All和全參數微調差異未達顯著水準，顯示參數高效微調方法具一定應用潛力。惟於部分校準指標上，全參數微調仍略優。
3. 模型規模影響： 模型由 Base 擴展至 Large 並未帶來顯著性能提升，部分指標甚至略有下降，且伴隨能耗增加，使整體能效表現相對不利。