投稿類別：資訊類

篇名：基於參數高效微調之混合文本檢測系統研究：性能、校準、能源效率之比較與權衡分析

作者：

陳旭昇 私立精誠高中 二年級 510 班 22 號 普通科
林秉睿 私立精誠高中 二年級 510 班 12 號 普通科

指導老師：

洪宜慧

壹、前言

一、研究動機

隨著大型語言模型（Large Language Model, LLM）的快速發展，生成式 AI 已經能夠產出語句流暢、邏輯清晰的文本，使內容生成的成本大幅降低。這項技術在提升生產效率的同時，也對學術誠信與內容可信度帶來新的挑戰。目前多數 AI 文本檢測系統仍以二元分類為主，僅區分純人類撰寫與純機器生成文本。然而，在實際應用情境中，人機協作已相當普遍，混合文本逐漸成為常態。這類文本同時包含人類與 AI 的語言特徵，使其在結構與語氣上更為複雜，也提高了辨識難度，導致傳統檢測方法的準確率下降。

二、研究目的

本研究旨在解決現有檢測器難以識別混合文本及運算資源需求過高之問題：

（一） 驗證參數高效微調在檢測型任務可行性

（二） 評估不同模型架構的效能與能耗效益

（三） 允許大型模型在消費級硬體上運行

三、研究問題

基於上述動機與目的，本研究擬探討以下具體問題：

（一） 架構效能差異：在相同訓練條件，ModernBERT 與 DeBERTa 不同 Transformer 架構，在混合文本檢測任務中的分類效能表現為何？

（二） 微調策略差異：相較於全參數微調，LoRA 技術是否導致明顯的準確度下降？節省的訓練時間和能耗效益？

（三） 最佳模型配置：考量檢測敏感度、訓練成本、推論速度，何種模型微調策略最適合使用在資源受限的邊緣設備？

貳、文獻探討

一、DeBERTa（Decoding-enhanced BERT with disentangled attention）

(He et al., 2020) 指出，透過兩項關鍵技術改進 BERT 與 RoBERTa 的架構限。之後，(He et al., 2023) 結合 ELECTRA 的預訓練策略，提出了 DeBERTaV3，為目前同量級中表現最強的 Encoder 模型之一。在架構設計 (He et al., 2020)，傳統 BERT 將單詞內容與位置向量直接相加；而 DeBERTa 則採用解耦注意力機制（Disentangled Attention），將兩者分離，改以獨立向量分別表示內容與相對位置。在計算注意力權重時，模型會分開衡量內容對內容、內容對位置以及位置對內容的交叉依賴關係，使其能更細緻地捕捉單詞間的語法與語義關聯。雖然解耦機制主要關注相對位置，但絕對位置對於預測被遮蔽詞彙（Masked Tokens）依然至關重要。因此，DeBERTa 在 Softmax 層前引入了增強型遮罩解碼器（Enhanced Mask Decoder, EMD），將絕對位置資訊重新納入解碼階段，幫模型更準確地預測上下文。在版本

DeBERTaV3 中，(He et al., 2023) 引入替換詞偵測（Replaced Token Detection, RTD）取代傳統的 MLM。避免生成器與判別器共享嵌入層所導致的優化衝突（Tug-of-war dynamics），研究團隊提出梯度解耦嵌入共享（Gradient-Disentangled Embedding Sharing, GDES），顯著提升訓練效率與下游任務的表現。

二、ModernBERT (Warner et al., 2024)

將近年來在解碼器（Decoder-only）模型中成功的技術，移植回編碼器（Encoder-only）架構，解決傳統 BERT 架構老化與長文本處理能力不足的問題。在架構設計上 (Warner et al., 2024)，模型採用旋轉位置編碼（Rotary Positional Embeddings, RoPE）取代傳統的絕對位置編碼，有效增強了處理長距離依賴的能力，使其原生支援達 8192 tokens 的序列長度。在注意力機制方面，模型交替使用全局注意力（Global Attention）與滑動窗口注意力（Sliding Window Attention），透過在不同層之間切換運算邏輯，顯著降低了處理長文本時的記憶體需求，同時保留了捕捉全局上下文資訊的能力。此外，模型以 GeGLU 激活函數 替換了傳統的 GeLU，透過門控機制提升了非線性表達能力。模型導入了 Flash Attention 技術並支援 Unpadding 機制，這使得模型在處理批次資料時僅需計算有效的 token，避免了對填充位（Padding）的無效運算，進而大幅提升了訓練與推理階段的吞吐量。

三、LoRA（Low-Rank Adaptation）

(Hu et al., 2022) 對於預訓練權重矩陣$W_0 \in R^{d\times k}$，LoRA 將更新量ΔW分結為兩個低秩矩陣乘積$A \in R^{r\times k}$、$B \in R^{d\times r}$，秩$r \ll \min(d,k)$能大幅降低顯存需求，向前傳輸公式為$h = W_0x + \Delta Wx = W_0x + BAx$，矩陣 A 用高斯分布初始化，矩陣 B 初始為 0，確保訓練一開始$\Delta W = 0$

表一：模型配置

模組名稱	微調範圍	效能與資源特性
q_proj, v_proj	僅針對 Transformer 的 Query 與 Value 投影矩陣。	參數量通常小於原模型 1%，效能與全參數微調相當。
all-linear	應用於模型中所有的線性層。	收斂效果優於僅微調W_q, W_v，能更全面強化特徵提取能力。

表一資料來源：研究者繪製

本研究選擇 DeBERTaV3 與 ModernBERT 作為 LoRA 微調的實驗對象，主要基於以下因果關係：

一、傳統精緻化架構 vs. 現代高效架構的對比： DeBERTaV3 代表了 Encoder-only 架構在任務特化上的巔峰（透過解耦注意力精確捕捉語義）；而 ModernBERT 則代表了借鑒 LLM 經驗後的進化體透過 RoPE 與 Flash Attention 提升長文本與運算效率。

二、探討 PEFT 在不同位置編碼下的適應性：LoRA 在作用於相對位置偏差（DeBERTa）與旋轉位置編碼（ModernBERT）這兩種截然不同的注意力機制時，其參數更新的效率與特徵漂移程度值得深入探究。

三、效能基準建立： 透過這兩款在同規模量級中表現最強的模型，本研究能更具 代表性地評估 LoRA 的 all-linear 配置在處理極端語義任務與長文本任務時的通用性。

參、研究方法

一、研究流程

圖一：研究流程圖

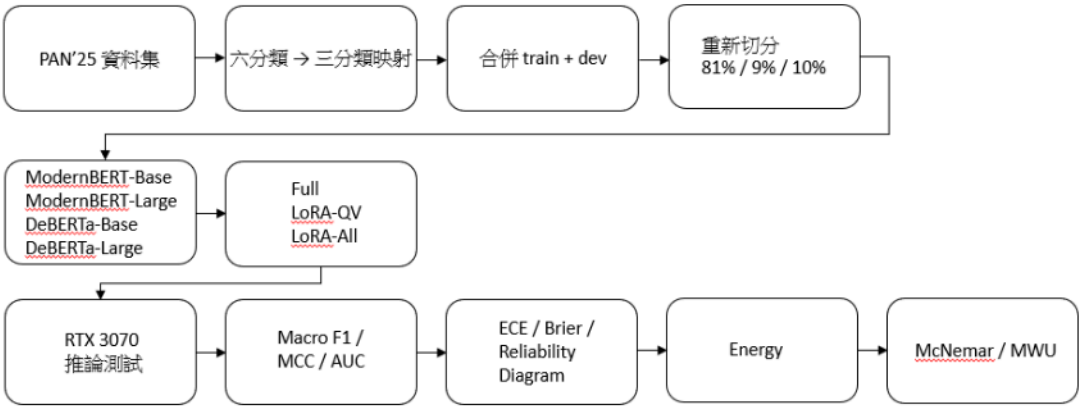

圖一資料來源：研究者繪製

二、研究設備

為兼顧高強度模型訓練與落地推論測試之情境模擬，本研究採用雙環境架構設計，並嚴格控制軟體版本，以確保實驗之可重現性與公平性。硬體設備訓練環境使用 RunPod 雲端運算平台（NVIDIA RTX 4090，24GB VRAM），用於全參數微調及大型模型訓練。該環境可提供高算力與充足顯存，以支援完整參數更新與大型模型實驗。本地推論環境使用（NVIDIA RTX 3070，8GB VRAM），用於模擬消費級硬體之實際部署場景。此設計可評估模型於資源受限條件下之實務可行性與能源效率。此雙環境配置可同時評估模型在「高效能訓練」與「實務部署推論」兩種情境下之表現差異。軟體環境 Python 3.10.19、Torch 2.6.0+cu124、Transformers 4.57.6、peft 0.18.1、Accelerate 1.12.0、Pandas 2.3.3、Numpy 2.2.6、Datasets 4.5.0、Scikit-learn 1.7.2、statsmodels 0.14.6、Pynvml 13.0.1、matplotlib 3.10.8、tqdm 4.67.1

三、資料集與標籤工程

資料集來源本研究使用了公開資料集「PAN'25 Generative AI Detection: Human-AI Collaborative Text Classification」，該資料集由多個研究機構共同發布於 Zenodo (DOI: 10.5281/zenodo.14966981)。該資料集旨在辨識文本中人類與大型語言模型之參與程度，原始資料包含六種類別：Fully human-written、Human-written, then machine-polished、Human-initiated, then machine-continued、Machine-written, then human-edited、Machine-written, then machine-humanized、Deeply-mixed text

四、標籤工程與三分類映射

為符合本研究之核心目標探討人類與 AI 生成文本之辨識與混合情境，本研究將原始六分類重新映射為三分類問題

表二：映射表格

原始標籤	本研究分類
Fully human-written	Human
Machine-written, then machine-humanized	AI
Human-written, then machine-polished	Mixed
Human-initiated, then machine-continued	Mixed
Machine-written, then human-edited	Mixed
Deeply-mixed text	Mixed

表二資料來源：研究者繪製

本研究嚴格定義 Mixed 為包含人類實質介入（如編輯、續寫、提供核心論點）之文本。針對 Machine-humanized 標籤，因其生成與潤飾過程均由機器完成，並未包含人類的參與，故依據其生產源頭將其歸類為 AI。

其中各分類定義 Human：完全由人類撰寫、AI：完全由人工智慧生成、Mixed：人類與人工智慧共同參與撰寫或修改

四、資料與處理與 Tokenization

所有文本經 tokenizer 編碼後，統一截斷或填充至最大長度 512 tokens，以確保不同模型在相同輸入長度條件下進行公平比較，統一最大長度可降低不同模型因輸入長度差異造成的計算量偏差，亦利於後續推論延遲與能耗之可比性

資料預處理流程包含：

（一） 標籤映射（六分類 → 三分類）

（二） 文本 tokenization

（三） Padding 與 truncation（最大長度 512）

（四） 移除異常或空文本

五、資料集切分策略

原始資料集提供 train 與 dev 兩個子集，然而兩者在各分類之資料數量分布存在不均勻情形。為避免特定分類集中於單一子集而影響模型訓練與評估公平性，本研究首先將 train 與 dev 合併為完整資料集，並重新進行隨機切分。此做法可確保各分類在訓練集、驗證集與測試集中具有較為一致之分布，有助於提升模型評估之穩定性與可靠性。接著，本研究將完整的資料集隨機切分為 90%為開發資料 10%為盲測集

盲測集在模型訓練與參數調整過程中完全不參與任何訓練或驗證程序，僅用於最終性能評估，以模擬模型面對未見過資料時的實際表現，並評估模型之泛化能力。隨後將開發資料進一步切分為：90%為訓練集 10%為驗證集

六、實驗設計

本研究採變因控制法，固定隨機種子（seed=42）與等效批次大小（Total Batch Size=32），LoRA 之 Rank （r）=32，Alpha=64。學習率依不同模型架構調整，以確保穩定收斂。實驗設計涵蓋了以下三個面向：分類性能、預測校準能力、推論能源效率。我們進行了以下實驗：

（一） 實驗一：模型架構比較

實驗目的：比較 DeBERTa-v3-base 與新架構 ModernBERT-base 兩個模型在「全參數微調」下的效能。

實驗設定：DeBERTa-v3-base Learning Rate=2e-5、ModernBERT-base Learning Rate=8e-6、Epochs=3

（二） 實驗二：微調策略探討

實驗目的：驗證 LoRA（低秩適應）是否優於全參數微調，並比較不同適應模組的影響，DeBERTa 採用 disentangled attention，因此選擇 q_proj 與 v_proj 作為局部調整模組，模型使用 DeBERTa-v3-base。

實驗設定：LoRA-QV（僅調整 Query/Value）、LoRA-All（微調所有線性層）、Learning Rate = 2e-4

（三） 實驗三：Large 模型 LoRA 效率比較

實驗目的：分析在大型模型中使用 LoRA 是否能有效降低計算資源與時間成本，模型使用 DeBERTa-v3-large 與 ModernBERT-large。

實驗設定：DeBERTa-v3-large Learning Rate=5e-5、ModernBERT-large Learning Rate=1e-4

（四） 實驗四：模型規模比較

實驗目的：分析 Large 模型相較於 Base 模型有無顯著提升以及資源消耗與性能的性價比。

實驗設定：DeBERTa-v3-large 模型與 DeBERTa-v3-base。

（五） 實驗五：ModernBERT LoRA Target 比較

實驗目的：比較 ModernBERT 在不同 Target Modeules 下的適應能力，其中 ModernBERT 因為採用 fused QKV projection 結構，因此以 QKV 作為局部調整模組。

實驗設定：比較 ModernBERT-QKV（僅調整 Query/Key/Value）與 ModernBERT-All（微調所有線性層），Learning Rate= 2e-4，Epochs = 3。

七、評估指標

表三：評估指標

Macro F1	計算各類別 F1-score 後取平均，不考慮類別比例。
Accuracy	正確預測比例。
MCC	綜合 TP、TN、FP、FN 的相關係數指標。
AUC（One-vs-Rest）	每個類別對其他類別的區分能力。
Expected Calibration Error（ECE）	衡量模型預測機率與實際正確率的差距。
Log Loss	衡量機率預測與真實標籤的距離。
Brier Score	機率預測的平方誤差。
Latency	單筆推論時間。
Throughput（samples/s）	每秒可處理樣本數。
平均功率（W）	GPU 運行時平均耗電功率。
推論總能耗（J）	推論階段總能量消耗。
Carbon Emission（gCO2）	推論總能耗估算碳排放量，作為能源影響延伸指標。

表三資料來源：研究者繪製

肆、研究分析與結果

一、整體性能與架構差異

本研究將 Macro F1 ≥ 0.98 視為高性能區間，係基於模型間差距已小於 0.005，且統計檢定未達顯著差異之情境。如表四所示，各模型於三分類任務之整體表現存在明顯差異。ModernBERT-Base（Full）於盲測集達 Macro F1 0.9851、Accuracy 98.49%，為本研究中表現最佳之模型；ModernBERT-Base（LoRA-All）亦達 Macro F1 0.98416，與 Full 僅差約 0.001。兩者在 MCC 與 AUC 指標上亦呈現高度一致。相較之下，DeBERTa-Base（LoRA-QV）Macro F1 為 0.94826，低於 ModernBERT 系列。此差距並非單一指標波動，而是在多項評估指標上皆呈現一致趨勢，顯示模型架構差異對混合文本辨識具有顯著影響。當 Macro F1 已達 0.98 以上區間時，模型間之性能差距已相對有限，顯示分類表現進入高位區間。

二、統計檢定與決策分布差異

為避免僅以平均指標判斷模型優劣，本研究進一步以 McNemar’s Test 比較模型預測結果之決策分布差異。ModernBERT-Base（Full）與 ModernBERT-Base（LoRA-All）之 $p = 0.0763$，未達顯著差異，顯示兩者在統計上可視為決策行為相近。然而，ModernBERT-Base（Full）與 ModernBERT-Large（LoRA-All）之

$p = 9.07 \times 10^{-10}$（$p \ll 0.01$），達顯著差異。值得注意的是，儘管 Large 與 Base 在決策分布上存在統計差異，其 Macro F1 並未提升，反而略為下降。此結果顯示，模型規模擴張可能改變決策行為，但該改變未對整體性能帶來明顯提升。

三、規模擴張與能源代價

如圖三所示，ModernBERT-Base（LoRA-All）與 ModernBERT-Large（LoRA-All）在性能已接近高位區間之情境下，規模擴張可能導致邊際效益下降之情形。推論階段 ΔMacro F1 = -0.00297; ΔEnergy = +146,873.75 J（約增加 97.6%）以盲測集完整推論為基準，Large 模型之總能耗增加約 97.6%，但未帶來性能提升，反而略為下降。圖九進一步放大 Base 模型之比較，可見 ModernBERT-Base（Full）、LoRA-All 與 LoRA-QV 三者之 Energy 落於相近區間，而性能差距亦相當有限。此現象顯示，在性能已接近高位區間之情境下，規模擴張可能導致邊際效益下降之情形。

四、預測可靠性與校準能力

除分類性能外，本研究亦評估模型之預測校準能力。圖二顯示：

（一） ModernBERT-Base（Full）ECE 為 0.01151

（二） ModernBERT-Base（LoRA-All）ECE 為 0.01278

（三） ModernBERT-Large（LoRA-All）ECE 為 0.01423

（四） DeBERTa-Base（LoRA-QV）ECE 為 0.03073

ModernBERT 系列於 ECE、Brier Score 與 Log Loss 指標上皆優於 DeBERTa。

圖四之 Reliability Diagram 顯示，ModernBERT-Base（Full）之曲線較為貼近理想對角線，表示其預測信心與實際命中率之對應關係較為一致，並且也能看出 Large 模型相較於 Base 模型並無顯著優勢。

錯誤信心分析表五顯示：

（一） ModernBERT-Base（LoRA-All）高信心錯誤比例為 73.84%

（二） ModernBERT-Large（LoRA-All）為 64.21%

（三） Mann－Whitney U 檢定 $p = 2.20 \times 10^{-3}$（$p < 0.01$）

除顯著性外，亦觀察到錯誤信心分布之中位數存在明顯差異。此結果顯示，即使整體性能相近，模型規模擴張仍可能改變錯誤情境信心分布結構。

表四：主要模型各項指標比較

模型配置	總體準確率	宏觀 F1	校準誤差	平均延遲	平均功耗	總能耗
ModernBERT-Base（Full）	98.49%	0.9851	0.0115	25.53	163.41	150866.5
ModernBERT-Base（LoRA-All）	98.39%	0.9841	0.0127	25.71	161.86	150471.7
ModernBERT-Large（LoRA-All）	98.08%	0.9811	0.0142	37.68	218.20	297345.4
DeBERTa-Base（LoRA-Q）	94.96%	0.9482	0.0307	21.10	192.56	146974.7

表四資料來源：研究者繪製

表五：模型錯誤樣本信心分佈特徵與 Mann-Whitney U 檢定結果

Model	Mean Conf	Median Conf	Error Conf > 0.9	Mixed Share	MWU p-value
ModernBERT-Base（LoRA-All）	0.9154	0.9871	73.84%	51.52%	-
ModernBERT-Large（LoRA-All）	0.8851	0.9728	64.21%	46.52%	2.1957e-03

表五資料來源：研究者繪製

圖二：不同模型架構與微調策略之校準誤差分析

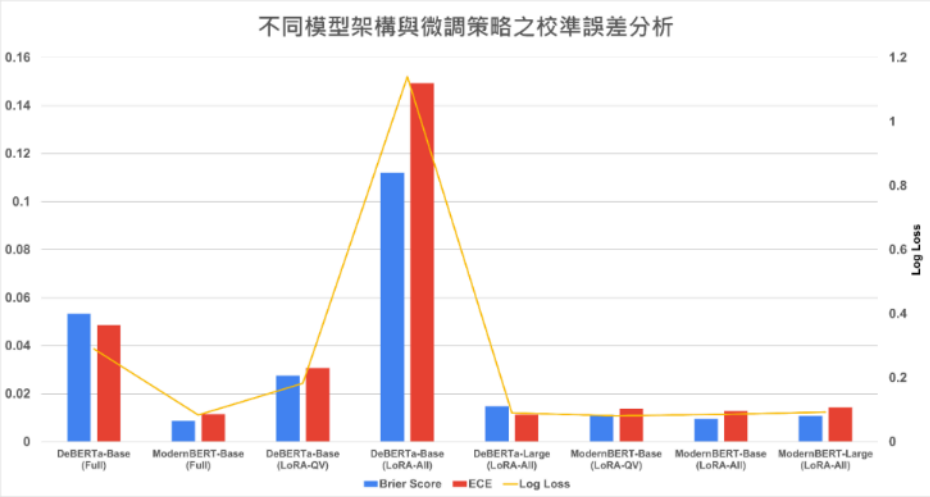

圖二資料來源：研究者繪製

圖三：模型效能與總能耗之權衡分析

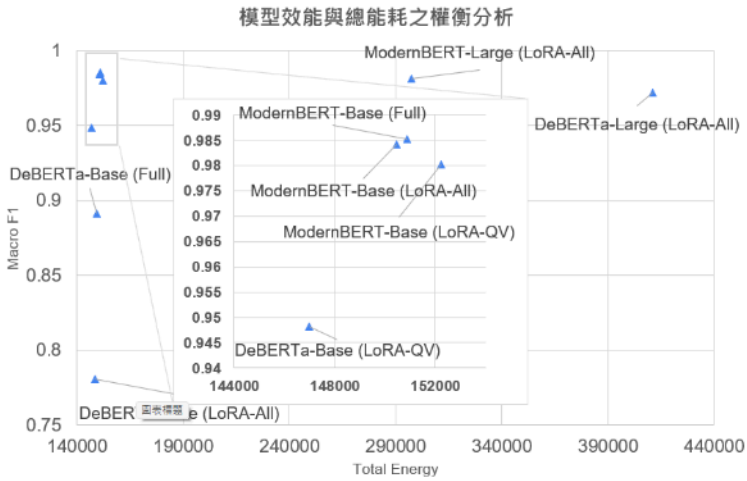

圖三資料來源：研究者繪製

圖四：Reliability Diagram (Direct Data Mapping)

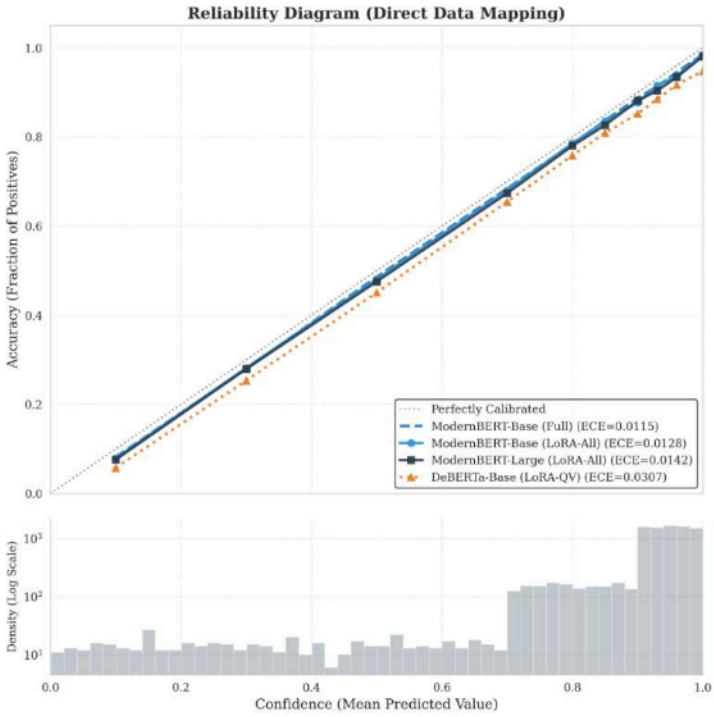

圖四資料來源：研究者繪製

伍、研究結論與建議

一、研究結論

本研究透過三分類混合文本任務，結合性能、統計檢定、能源效率與預測校準分析，獲得以下觀察：

（一） 架構差異對性能表現具有明顯影響。ModernBERT 在 Macro F1 與校準能力上均優於 DeBERTa，顯示新架構於本任務中具較佳表現。

（二） 參數高效微調策略具實務可行性。ModernBERT-Base(LoRA-All)與 Full 在統計上未達顯著差異，顯示其可作為全參數微調之替代方案。

（三） 規模擴張未必帶來性能提升。Large 模型雖改變決策分布，但未提升整體表現，且能源與延遲顯著增加。

（四） 當分類性能接近飽和時，優化方向可轉向能源效率與預測可靠性。在 Macro F1 已達 0.98 以上之情況下，持續追求微幅分數提升之邊際效益可能有限。

二、研究建議

未來 AI 模型評估可同時納入分類性能、預測校準能力與能源效率指標，以建立更完整且具實務意義之評估框架。

三、研究限制與未來方向

本研究仍存在若干限制。首先，本研究未進行跨資料集驗證，本研究以 PAN’25 資料集為基礎，並採六分類映射為三分類之方式進行實驗，雖可更聚焦於人機混合文本之辨識問題，但不同資料分布或其他資料集情境下，模型表現仍可能有所差異。其次，本研究主要分析推論階段之能源效率與校準能力，訓練階段之長期碳排影響尚未納入完整比較。未來研究可進一步探討不同語域、不同生成模型來源之文本，檢驗模型在跨資料集情境下之穩定性；亦可結合更多校準方法或後處理策略，以提升高信心錯誤之控制能力，建立更具實務應用價值之混合文本檢測系統。

陸、參考文獻

一、He, P., Liu, X., Gao, J., & Chen, W. (2020). DeBERTa: Decoding-enhanced BERT with disentangled attention. International Conference on Learning Representations.

二、He, P., Gao, J., & Chen, W. (2023). DeBERTaV3: Improving DeBERTa using ELECTRA-style pre-training with gradient-disentangled embedding sharing. The Eleventh International Conference on Learning Representations.

三、Hu, E. J., Shen, Y., Wallis, P., Allen-Zhu, Z., Li, Y., Wang, S., ... & Chen, W. (2021). LORA: Low-rank adaptation of large language models. International Conference on Learning Representations.

四、Warner, B., Chaffin, A., Clavić, B., Weller, O., Hallström, O., Taghadouini, S., ... & Poli, I. (2024). Smarter, better, faster, longer: A modern bidirectional encoder for fast, memory efficient, and long context finetuning and inference. arXiv. https://doi.org/10.48550/arXiv.2412.13663

五、Stamatatos, E., Kestemont, M., Kredens, K., Pezik, P., Heini, A., Bevendorff, J., Potthast, M., & Stein, B. (2025). *The PAN25 Generative AI Authorship Verification Dataset* (Version 1.0) [Data set]. Zenodo. https://zenodo.org/records/14966981